

2026/07/21

コメント用リンク
(PCで開きたい人はクリック)



信号処理特論 I

13. 深層展開

早川 諒

E-mail: hayakawa@go.tuat.ac.jp

目次

◆ 雜談

◆ 本題

雑談（抜粋）

Q. 今回のPnPの授業より前に、授業の課題レポートとしてPnPの不動点収束の文献を選んで提出したら、同じ文献が今回の授業スライドで引用されてました。授業スライドが公開される前に、自分自身で文献調査したものであってスライドから安易に引用したものじゃないので許してください！

A. 🙌

Q. なんか急に暑くてやばいです。
おすすめの避暑アイテムがあれば教えてください！

A. クイックシャットの日傘くらいですかね


雑談（抜粋）

- Q. 説明されていたら申し訳ありません。最後のところで標準偏差40のノイズに対するノイズ除去の画像のところ、25、35、50の画像から40のいい感じに導けるみたいな話だったのかなと認識しているのですが、25、35、50が作れるなら40の画像もその三つから導かなくても作れるのではないかと思ってしまいました。どうしてその三つがある状況で、40のが欲しくなるのかな？と思って聞いていました。この辺り良く分かってなかったので見当違いな質問でしたら申し訳ありません。
- A. (DnCNNの場合は) 標準偏差40のノイズを除去するためには標準偏差40のノイズ除去のためのネットワークを改めて(標準偏差40のノイズを含んだ画像のデータで)学習しないといけない、という感じです


CE | ノイズ除去結果とPSNR(再掲)

- ✓ 異なる標準偏差のノイズに対応する複数のノイズ除去をCEで組み込むと特性が改善

標準偏差40のノイズに対するノイズ除去の結果



標準偏差25に
対するDnCNN
(19.92 dB)



標準偏差35に
対するDnCNN
(26.44 dB)



標準偏差50に
対するDnCNN
(27.39 dB)



CE
(27.77 dB)

[G. T. Buzzard, S. H. Chan, S. Sreehari, and C. A. Bouman, "Plug-and-play unplugged: Optimization-free reconstruction using consensus equilibrium," SIAM J. Imaging Sci., vol. 11, no. 3, pp. 2001–2020, Jan. 2018.]

より抜粋

目次

◆ 雜談


◆ 本題

今日の内容

- ◆ モデルベース信号復元とデータ駆動信号復元(復習)
- ◆ 深層展開
- ◆ 深層展開の応用例

線形観測からの信号復元（再掲）

- ✓ 未知ベクトル $\mathbf{x}^* \in \mathbb{R}^N$ を
その線形観測 $\mathbf{y} = \mathbf{A}\mathbf{x}^* + \mathbf{v} \in \mathbb{R}^M$ から推定



例：◆ 圧縮センシング
◆ 画像復元
◆ 無線信号検出

正則化付き最適化に基づく復元の一般形（再掲）

- ✓ **観測モデルの情報**と**復元対象の信号に関する事前知識**をどちらも活用

基本的な形： $\hat{x} = \arg \min_{x \in \mathbb{R}^N} \left\{ \frac{1}{2} \|y - Ax\|_2^2 + \lambda g(x) \right\}$


正則化パラメータ

データ忠実性

観測モデル $y = Ax^* + v$ の情報を活用

正則化

x^* に関する事前知識を活用



ℓ_1 正則化を用いた問題に対するISTA

✓ 圧縮センシング（スパース信号の復元）のための手法の一つ

ℓ_1 正則化を用いた最適化問題

$$\underset{\mathbf{x} \in \mathbb{R}^N}{\text{minimize}} \left\{ \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1 \right\}$$




近接勾配法 (ISTA)

$$\begin{aligned} \mathbf{u}^{(k+1)} &= \mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} &= \text{prox}_{\gamma g}(\mathbf{u}^{(k+1)}) \end{aligned}$$

$\gamma > 0$: パラメータ

弱しきい値関数




信号復元のためのアプローチ（再掲）

- ✓ 信号復元によって得られた知見の信頼性を担保するためには、
情報処理プロセスの解釈性や説明性が重要

数理最適化を用いたモデルベース手法

目的関数を設計・最小化


（解釈性○，汎用性○，復元精度△）



機械学習を用いたデータ駆動型手法

データから，観測値→復元結果の変換を学習

（**解釈性△**，**汎用性△**，復元精度○）



融合


- ◆ 深層展開
- ◆ Plug and play
- ⋮

アルゴリズム設計への機械学習技術の応用(再掲)

正則化の設計

$$\underset{\mathbf{x} \in \mathbb{R}^N}{\text{minimize}} \left\{ \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda g(\mathbf{x}) \right\}$$


Plug-and-Play (PnP)



パラメータの設計

$$\begin{aligned} \mathbf{u}^{(k+1)} &= \mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} &= \text{prox}_{\gamma g}(\mathbf{u}^{(k+1)}) \end{aligned}$$

深層展開



今日の内容


- ◆ モデルベース信号復元とデータ駆動信号復元（復習）
- ◆ **深層展開**
- ◆ 深層展開の応用例

アルゴリズムのパラメータ設定

- ✓ 反復アルゴリズムには、多くの場合**パラメータ**が含まれる
→ パラメータの値の選択が復元精度や収束速度に大きく影響

元のISTA



$$\begin{aligned} \mathbf{u}^{(k+1)} &= \mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} &= \text{prox}_{\gamma g}(\mathbf{u}^{(k+1)}) \end{aligned}$$



復元結果 $\hat{\mathbf{x}}$ を真の値 $\mathbf{x}^*$ により近くするには
どのようにパラメータ $\gamma_1, \gamma_2, \dots, \gamma_K$ を設定したらよいか？

深層展開の概要

- ✓ 反復アルゴリズムの処理をニューラルネットワークに見立て、
誤差逆伝播法などの技術を用いてアルゴリズムのパラメータを学習
- ◆ ISTAベースのアルゴリズムのパラメータを学習させる
LISTA (Learned ISTA) [1]をはじめとして、さまざまな問題に応用



[1] K. Gregor and Y. LeCun, "Learning fast approximations of sparse coding," in Proc. the 27th ICML, Jun. 2010, pp. 399–406.

単純なISTAの例 (1 / 2)

✓ ISTAのパラメータ $\gamma_0, \gamma_1, \dots$ を学習

$$\mathbf{u}^{(k+1)} = \mathbf{x}^{(k)} - \gamma_k \nabla f(\mathbf{x}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \text{prox}_{\gamma_k g}(\mathbf{u}^{(k+1)})$$

目的

ISTAによる復元結果 $\hat{\mathbf{x}}(\gamma_0, \gamma_1, \dots, \gamma_K)$ が真の値 $\mathbf{x}^*$ に近くなるパラメータ $\gamma_0, \gamma_1, \dots, \gamma_K$ を求める

基本的な流れ

1. 学習のためのデータ $(\mathbf{x}_1^*, \mathbf{A}_1, \mathbf{y}_1), \dots, (\mathbf{x}_B^*, \mathbf{A}_B, \mathbf{y}_B)$ を用意

2. 損失関数を最小化: $\underset{\gamma_0, \gamma_1, \dots, \gamma_K \in \mathbb{R}}{\text{minimize}} \left\{ \frac{1}{BN} \sum_{b=1}^B \|\hat{\mathbf{x}}_b(\gamma_0, \gamma_1, \dots, \gamma_K) - \mathbf{x}_b^*\|_2^2 \right\}$


$\mathbf{x}_b^*$ の推定値

$= E(\gamma_0, \gamma_1, \dots, \gamma_K)$

パラメータによる微分 $\frac{\partial E}{\partial \gamma_k}$ を求めるには？

単純なISTAの例(2/2)

- ✓ アルゴリズムの各反復での更新がパラメータに関して微分可能なら、誤差逆伝播法でパラメータの値を学習可能



深層展開の特徴

メリット

- ◆ データに基づいてパラメータを学習できる
 - ❖ アルゴリズムの復元精度や収束速度を改善可能
- ◆ アルゴリズムの構造を反映したネットワークを構築できる
 - ❖ 信号の観測モデルや信号に関する事前知識はそのまま使用可能
- ◆ 学習パラメータが比較的少ないので学習が楽＋結果の解釈がしやすい
 - ❖ 新たな発見があるかも？

学習率, 初期値, ミニバッチサイズ, ...

デメリット(?)

- ◆ 学習時のハイパーパラメータの調整は必要
 - ❖ Optuna [2]などのツールによってある程度自動的な探索は可能
- ◆ 基本的には, 問題設定に合わせてその都度学習が必要

深層展開での検討事項(1/5)

ベースとなる最適化問題・アルゴリズムの選択

- ◆ どのような最適化問題をスタート地点にするか
- ◆ どのようなアルゴリズムを使うか
 - ❖ 反復ごとの計算量
 - ❖ 収束速度
 - などに影響

例： $\underset{x \in \mathbb{R}^N}{\text{minimize}} \left\{ f(x) + g(x) \right\} \longrightarrow \text{ISTA, FISTA}$

$\underset{x \in \mathbb{R}^N, z \in \mathbb{R}^L}{\text{minimize}} \left\{ f(x) + g(z) \right\} \longrightarrow \text{交互方向乗数法 (ADMM)}$
 subject to $\Phi x = z$

$\underset{x \in \mathbb{R}^N}{\text{minimize}} \left\{ f(x) + g(x) + h(\Phi x) \right\} \longrightarrow \text{主双対近接分離法 (PDS)}$

深層展開での検討事項(2/5)

学習パラメータの埋め込み方

- ◆ どのパラメータを学習させるか
- ◆ どこまで元のアルゴリズムに忠実にするか
 - ❖ 思想やセンスが出るところ
 - ❖ 学習時間・最終的な復元精度などに影響

例: LISTA [1]

アルゴリズム中の観測行列の部分もパラメータと思って学習

TISTA [3]

観測行列はそのまま(学習せず)使い、ステップサイズなどのみ学習

[1] K. Gregor and Y. LeCun, "Learning fast approximations of sparse coding," in Proc. the 27th ICML, Jun. 2010, pp. 399–406.


[3] D. Ito, S. Takabe, and T. Wadayama, "Trainable ISTA for Sparse Signal Recovery," *IEEE Trans. Signal Process.*, vol. 67, no. 12, pp. 3113–3125, Jun. 2019.

深層展開での検討事項(3/5)

学習方法

- ◆ 学習アルゴリズムの選択
 - ✧ 確率的勾配降下法
 - ✧ RMSProp
 - ✧ Adam
 - ⋮
- ◆ インクリメンタル学習の有無


学習対象となる層の数を
少しずつ増やしながら学習



深層展開での検討事項(4/5)

損失関数の設計

- ◆ 問題設定に合わせて学習時の損失関数を設計
 - ◆ 信号復元であれば、基本的には平均二乗誤差



損失関数の違いによる
学習結果の違い


損失：最適化問題の
目的関数

損失：平均二乗誤差

深層展開での検討事項(5/5)

学習・テスト用データの作成

- ◆ 基本的にはデータを用意
- ◆ もしデータの分布が既知or仮定できるならその分布に従って生成
 - ✧ 無線通信の信号検出などでは、送信側もある程度設計できるので分布を既知とできる場合もある



QPSK

(Quadrature Phase Shift Keying)

11, 01, 00, 10というビット列をそれぞれ

$1+j$, $-1+j$, $-1-j$, $1-j$

に変調して送信

深層展開の応用例


- ✓ さまざまな分野で応用されている [4, 5]
 - ◆ 圧縮センシング・スパースモデリング
 - ◆ 画像復元・イメージング
 - ◆ 無線通信
 - ◆ 符号理論
 - ◆ グラフ信号処理
 - ◆ 制御理論
 - ◆ 微分方程式

[4] V. Monga, Y. Li, and Y. C. Eldar, "Algorithm unrolling: Interpretable, efficient deep learning for signal and image processing," IEEE Signal Processing Magazine, vol. 38, no. 2, pp. 18–44, Mar. 2021.

[5] 和田山 正, "モデルベース深層学習と深層展開," 森北出版, 2023.

学習結果の解釈

- ✓ 学習されたパラメータは、単調ではなくジグザグに変化することが多い
→ なぜか？



← ISTAのステップサイズの
学習結果の例

チェビシェフステップによる解釈[6]

…チェビシェフ多項式から定まる数列

(シンプルな設定では収束加速を証明可能)との類似性を指摘

[6] S. Takabe and T. Wadayama, "Convergence acceleration via Chebyshev step: Plausible interpretation of deep-unfolded gradient descent," IEICE Trans. Fundam. Electron. Commun. Comput. Sci., vol. E105.A, no. 8, pp. 1110–1120, Aug. 2022.

デモコード

https://colab.research.google.com/drive/1huG53IBV_t6oLsqjZMYTtjL1e0gHd81T?usp=sharing

今日の内容


- ◆ モデルベース信号復元とデータ駆動信号復元（復習）
- ◆ 深層展開
- ◆ **深層展開の応用例**

無線信号検出

- ✓ 送信シンボルベクトル $\mathbf{x}^* \in \mathbb{C}^N$ を
受信信号ベクトル $\mathbf{y} = \mathbf{A}\mathbf{x}^* + \mathbf{v} \in \mathbb{C}^M$ から推定


MIMOシステム
(Multiple-Input Multiple-Output)

高速・大容量の通信



従来手法の課題

- ✓ 従来多くの信号検出法は、
- ・ **大規模（数十～数百本のアンテナ）** で
 - ・ **過負荷（受信アンテナ数 < 送信アンテナ数）**
- の場合、復元精度が悪い or 計算量的に実行不可能



学習型射影勾配法に基づく信号検出[7]

QPSK変調を用いた場合の等価な実数モデル

$$\mathbf{y} = \mathbf{A}\mathbf{x}^* + \mathbf{v} \in \mathbb{R}^{2M}, \quad \mathbf{x}^* \in \{1, -1\}^{2N}$$


勾配降下のような処理

学習型射影勾配検出法[13] $\mathbf{u}^{(k+1)} = \mathbf{x}^{(k)} + \gamma_k \mathbf{W}(\mathbf{y} - \mathbf{A}\mathbf{x}^{(k)})$
 $(\mathbf{W} = \mathbf{A}^\top (\mathbf{A}\mathbf{A}^\top + \alpha \mathbf{I})^{-1})$

$$\mathbf{x}^{(k+1)} = \tanh\left(\frac{\mathbf{u}^{(k+1)}}{|\theta_k|}\right)$$

学習
パラメータ


推定値を 1 か -1 に近づける処理



$\gamma_k, \theta_k, \alpha$ を深層展開で学習


シミュレーション結果[7]

- ✓ 計算量が同程度の従来手法と比べて小さい誤り率を達成




学習されたパラメータの値[7]

✓ 学習されたパラメータは、どちらもジグザグの形状となった




動画の圧縮イメージング [8]

- ✓ 高フレームレートの動画(3次元データ)を
圧縮された画像(2次元データ)から再構成



システムモデル



目的：観測画像 Y とマスク $M_1, \dots, M_{N_t}$ から未知動画 $X_1, \dots, X_{N_t}$ を再構成

再構成アルゴリズム

◆ 数理最適化ベース

❖ GAP [9], DeSCI [10], ...

◆ 機械学習ベース

❖ E2E-CNN [11], reversible SCI net [12], ...

◆ 融合型

❖ **PnP-ADMM** [13], online PnP [14], ...

[9] X. Yuan, "Generalized alternating projection based total variation minimization for compressive sensing," in 2016 IEEE International Conference on Image Processing (ICIP), 2016, pp. 2539–2543.

[10] Y. Liu, X. Yuan, J. Suo, D. J. Brady, and Q. Dai, "Rank Minimization for Snapshot Compressive Imaging," IEEE Trans. Pattern Anal. Mach. Intell., vol. 41, no. 12, pp. 2990–3006, Dec. 2019.

[11] M. Qiao, Z. Meng, J. Ma, and X. Yuan, "Deep learning for video compressive sensing," APL Photonics, vol. 5, no. 3, Mar. 2020.


[12] Z. Cheng et al., "Memory-Efficient Network for Large-scale Video Compressive Sensing," in 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, pp. 16241–16250.

[13] X. Yuan, Y. Liu, J. Suo, F. Durand, and Q. Dai, "Plug-and-Play Algorithms for Video Snapshot Compressive Imaging," IEEE Trans. Pattern Anal. Mach. Intell., vol. 44, no. 10, pp. 7093–7111, Oct. 2022.

[14] Z. Wu, C. Yang, X. Su, and X. Yuan, "Adaptive Deep PnP Algorithm for Video Snapshot Compressive Imaging," Int. J. Comput. Vis., vol. 131, no. 7, pp. 1662–1679, Jul. 2023.

ノイズレベルパラメータ

- ✓ PnP-ADMMでは、
観測モデルに基づく更新と**動画に対するノイズ除去**を反復



例：◆ FFDNet [15]
◆ FastDVDnet [16]

動画像に対するノイズ除去


ノイズレベルパラメータ σ_k
(ノイズ除去の強さを表す)
を適切に設定する必要がある

[15] K. Zhang, W. Zuo, and L. Zhang, "FFDNet: Toward a fast and flexible solution for CNN based image denoising," IEEE Trans. Image Process., May 2018.

[16] M. Tassano, J. Delon, and T. Veit, "FastDVDnet: Towards Real-Time deep video denoising without flow estimation," in 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, Jun. 2020, pp. 1351–1360.

深層展開に基づくパラメータ学習[17]


- ✓ 深層展開によってノイズレベルパラメータ σ_k を学習



PnP-ADMM (展開版)


学習されたノイズレベルパラメータ

- ✓ 学習によって得られたパラメータ設定は
従来のパラメータ設定(手動で設計)と大きく異なる



再構成の精度

- ✓ 学習されたパラメータを用いたPnP-ADMMによってより良い復元精度を達成




再構成された動画（シミュレーションデータ）

- ✓ 学習されたパラメータを用いることで、車の詳細をより復元可能



原動画



観測



従来の
パラメータ




学習後の
パラメータ

再構成された動画（リアルデータ）

✓ リアルデータの復元結果でも改善が見られる


観測



従来の
パラメータ




学習後の
パラメータ



アンケート

[https://docs.google.com/forms/d/e/
1FAIpQLScqIJ0ImR5EUGL0DnN8qQhGtCdL77IzIW
Pox-l0dBnbaDFH-Q/viewform?usp=sharing](https://docs.google.com/forms/d/e/1FAIpQLScqIJ0ImR5EUGL0DnN8qQhGtCdL77IzIW-Pox-l0dBnbaDFH-Q/viewform?usp=sharing)

大学のアンケート



HOME >

★ 学修ポートフォリオ

★ 成績登録期間のお知らせ
成績登録期間中です。未着手の科目が存在します。
[成績登録へ](#)

★ What's NEW!!
新着お知らせはありません。

📖 本日の授業一覧(7/22)

時限	時間割コード	科目	リンク
2	106a0615	信号処理特論 I	お知らせ 授業アンケート 休講補講 LMS 授業情報