

M4CEA: A Knowledge-guided Foundation Model for Childhood Epilepsy Analysis



Yuanmeng Feng¹, Dinghan Hu¹, Tiejia Jiang², Feng Gao², Jiuwen Cao¹

1. Machine Learning and I-health International Cooperation Base of Zhejiang Province, and the Artificial Intelligence Institute, Hangzhou Dianzi University, Zhejiang, China
2. Department of Neurology, the Children's Hospital, Zhejiang University School of Medicine, National Clinical Research Center for Child Health, Hangzhou, China

概要


- 背景：小児てんかん解析には多様な EEG タスクが存在するが、既存の EEG 基盤モデルは小児 EEG の年齢依存的な特性を考慮していないため、適用が困難
- 目的：小児てんかん解析における複数タスクを単一モデルで処理できる EEG 基盤モデルの構築
- 方法：
 - 4 施設から収集した約 1,000 時間の小児 EEG で事前学習
 - エントロピーに基づくマスキングと学習可能な時間位置埋め込みを導入
 - 振幅と位相を再構成目標とした自己教師あり学習
- 結果
 - 全 8 つの下流タスクで比較手法（LaBraM 等）を凌駕
 - Grad-CAM による可視化で、モデルの注目領域が神経科医のアノテーション領域と一致

てんかん

- 幼少期において特に有病率の高い神経疾患の一つ
- 合併症：知的障害，発達障害
- 脳波（Electroencephalogram; EEG）による診断が主流

生後 1 年まで


102 件 / 10 万人



=

1 歳 – 12 歳


102 件 / 10 万人



>

11 歳 – 17 歳

21–24 件 / 10 万人



てんかんにおける EEG 解析手法

手動特徴量モデル

ドメイン知識から人手で
EEG 特徴量を設計

✗ 計算コストが高い

タスク特化深層学習モデル

教師あり学習により
EEG 特徴を獲得

✓ 手動設計が不要

✗ 大量のラベル付き EEG
が必要

✗ 単一タスクに特化

基盤モデル

自己教師あり学習により
EEG 特徴を獲得

✓ ラベル依存を大幅に低減

✓ 複数タスクへ適用可能

✗ 既存の基盤モデルは小児
EEG を考慮していない

小児てんかん EEG の解析における課題

小児特有の脳波特性：小児の脳波は成長とともに変化するため、成人の脳波とは異なり複雑

[Kaminska+, *Handbook of clinical neurology*, 2019]

- 非対称から対称へ
- 不規則から規則的へ

多岐にわたる臨床タスク


- 発作検出・分類, てんかん症候群分類, 睡眠段階分類など
- タスク間は相互に関連しているため, 包括的に理解できるモデルが必要

大規模な小児 EEG データセットの欠如

小児てんかん解析に特化した基盤モデルの構築が必要


提案手法：M4CEA

- 振幅変動を考慮した時間位置埋め込みの導入 (Learnable-time-positional Embedding)
- エントロピーに基づくマスク戦略の導入 (Knowledge-guided Mask Strategy)
- 1,092.3 時間の小児 EEG による事前学習




Learnable-time-positional Embedding

- 知見：小児 EEG の振幅は年齢とともに変化するため，時間領域に豊富な情報を含む
- 方法：振幅変動を考慮した学習可能な時間位置埋め込みの導入
 1. 学習可能な時間位置埋め込み ϵ_t を用意
 2. パッチ $p_{i,j}$ の移動平均と ϵ_t の要素積 ϵ_p を計算
 3. パッチ $p_{i,j}$ の畳み込み出力と ϵ_p を加算




パッチ化した EEG

時間位置埋め込み




Knowledge-guided Mask Strategy

- 知見：エントロピーは EEG の複雑性を反映（特に小児 EEG） [Lawhern+, *J. Neural Eng.*, 2018]
- 手法：Multi-scale Fluctuation-based Dispersion Entropy (MFDE) [Azami+, *IEEE Access*, 2019] をマスク確率に使用
 - **情報密度が高い複雑なパッチ**を優先的にマスク



事前学習

- 知見：小児 EEG は発達途上で不安定であるため、生信号の再構成による事前学習は困難
- 方法：マスクされたパッチにおける**振幅**と**位相**の**再構成誤差**を最小化 [França+, *Nat. Commun.*, 2024]




下流タスク（8 種類）


施設	タスク名	タスク内容	セグメント長
HUH	オンセット検出（OD）	2 クラス分類	4s
	アーチファクト検出（AD）	6 クラス分類	
Cork	低酸素性虚血性脳症の重症度分類（HIEG）	4 クラス分類	
CHSZ	発作型分類（STC）	4 クラス分類	
CHZU	発作型分類（STC）	4 クラス分類	30s
	小児てんかん症候群分類（CES）	7 クラス分類	
	睡眠段階分類（SSC）	3 クラス分類	
	てんかん様活動の検出（EAD）	セグメンテーション	
	棘徐波指数の定量化（SWIQ）	セグメンテーション	

ファインチューニング（下流タスクごと）

■ 分類タスク：



■ セグメンテーションタスク（EAD・SWIQ）：



下流タスクにおける結果（抜粋）


タスク名	指標	M4CEA	SOTA	差分
オンセット検出（HUH-OD）	Bal.Acc.	0.968	0.874	9.4%
アーチファクト検出（HUH-AD）		0.809	0.699	11.0%
HIE 重症度分類（Cork-HIEG）		0.940	0.769	17.1%
発作型分類（CHSZ-STC）		0.942	0.932	1.0%
発作型分類（CHZU-STC）		0.984	0.961	2.3%
小児てんかん症候群分類（CHZU-CES）		0.956	0.604	35.2%
睡眠段階分類（CHZU-SSC）		0.964	0.920	4.4%
てんかん様活動の検出（CHZU-EAD）	Sens.	0.735	0.540	19.5%
SWK 定量化（CHZU-SWIQ）	PCT-10	0.958	0.804	15.3%

アブレーション：マスク確率


- マスク確率：25%, 50%, 75%
- 考察：
 - 大域的な特徴を捉える必要があるタスク（左二つ）には高いマスク確率が適する
 - 局所的な特徴を捉える必要があるタスク（右二つ）には低いマスク確率が適する

大域的

発作型分類




睡眠段階分類




局所的

てんかん様活動検出



棘徐波指数の定量化




アブレーション：マスク戦略と時間位置埋め込み

手法	発作型分類	睡眠段階分類
KGM+LTPE (提案手法)	0.979	0.982
KGM+FTPE (固定埋め込み)	0.974	0.965
RM+LTPE (ランダムマスク)	0.972	0.978
KGM のみ	0.976	0.975
RM のみ	0.977	0.978

- Learnable-time-positional Embedding (LTPE)
 - 学習可能にすることで性能向上
 - 位相の再構成品質が向上
- Knowledge-guided mask strategy (KGM)
 - エントロピーに基づくマスク戦略のみではランダムマスクを下回る
 - LTPE と組み合わせることで性能向上
 - 損失の推移が安定

Grad-CAM による可視化

- Gradient Weighted Class Activation Mapping (Grad-CAM): モデルの予測に寄与した入力信号の領域を可視化する手法
- タスク：てんかん様活動検出
- 比較モデル：LaBraM, Patch TST
- 結果：M4CEA が最も多く専門医のアノテーションと一致



青枠：専門医によるアノテーション 赤枠：モデルの注目領域

考察

- Knowledge-guided mask strategy の効果：
情報密度の高いパッチを優先的にマスクすることで、モデルが強制的に臨床的に意味のある特徴を学習
- Learnable-time-positional Embedding の効果：
サンプルに対して固定の時間情報を付与しないことで、データセット間のサンプリング周波数の違いを吸収
- 事前学習データの効果：LaBraM などと異なり小児 EEG を用いて事前学習することで、小児 EEG 特有の年齢依存的な特徴を学習

研究の限界と今後の課題

- 1,000 時間の事前学習 EEG は今日の大規模医療 FM と比較して小規模
→ より**大規模な小児 EEG コーパス**が必要
- 下流タスクごとにフルファインチューニングが必要であるため、計算コストが高い
→ **パラメータ効率が良い手法の導入**が必要
- モデルが EEG にのみ対応
→ ECG や臨床テキストなどの**他のモダリティとの統合**

まとめ


- 小児てんかん解析のための EEG 基盤モデルである M4CEA を提案
- エントロピーに基づくマスク戦略と学習可能な時間位置エンコーディングが有効
- チャンネル数・信号長が異なる EEG に対してファインチューニング可能
- 全ての下流タスクにおいて SOTA を上回る性能
- Grad-CAM による可視化で、モデルの注目領域が神経科医のアノテーション領域と一致

コメント

- 公開されているコードの実装と論文とで一致しない部分が多くて困った
- エントロピーベースのマスクは自分もやってみたい
- EEG のサンプリング周波数が一定じゃないのに下流タスクで上手くいってるのが不思議
- LaBraM の後継モデルである NeuroLM の論文内で位相の再構成は学習にあまり貢献しないと書かれていたが、この論文内では効果的だったのが気になった

Appendix

振幅の分散（Hjorth activity）に基づく考察






■ 方法：

- 切り出したパッチごとに振幅の分散を計算
- 隣接する年齢群同士の分布を比較

■ 結果：

- 各年齢群間に有意差が見られた（t-検定）
- Normal グループ：年齢が上がるにつれて減少する傾向

Multi-scale Fluctuation-based Dispersion Entropy



- EEG のパッチを一定の窓幅 (τ) で区切り, 各窓の平均値を計算
- 正規累積分布関数 (NCDF) を用いて (0,1) の範囲に写像
- $1 - c$ の整数に量子化
- 窓幅 m , スライド d で差分パターン列 π を作成
- 差分パターン列の出現確率 P を求める
- エントロピーを計算

e.

$$z_s^{m,c} = [1 \ 1 \ 4] \xrightarrow{\Delta} \pi_{0,3} = [0 \ 3]$$

f.

$$P(\pi_{0,3}) = \frac{\text{Num}(\pi_{0,3})}{N - (m - 1)d} \rightarrow - \sum_{\pi} P(\pi_i) \log P(\pi_i)$$

学習時の損失関数

- 事前学習：フーリエ変換された振幅（Magnitude）と位相（Phase）の再構成誤差を最小化


$$Loss_{mag} = \frac{1}{N} \sum_{n=1}^N (Res_{mag} - Raw_{mag})^2$$

$$Loss_{phase} = \frac{1}{N} \sum_{n=1}^N (Res_{phase} - Raw_{phase})^2$$

- ファインチューニング：各タスクごとにクロスエントロピー損失を計算

$$Loss_{fine-tuning} = - \sum y \log \hat{y} \quad (y \text{ は真のラベル, } \hat{y} \text{ はモデルの予測値})$$

データセット





前処理

1. フィルタリング：
 - 50 Hz ノッチフィルタ
 - 0.5–70 Hz バンドパスフィルタ
2. リサンプリング：
 - CHZU: 1000 Hz のまま
 - CHSZ: 500/1000 Hz → 500 Hz
 - HUH: 256 Hz → 200 Hz
 - Cork: 200/256 Hz → 200 Hz
3. 振幅を 95 パーセンタイルで正規化



アブレーション：事前学習の有無

- 方法：事前学習＋ファインチューニングの場合とタスク特化で1から学習の場合を比較
- 結果：事前学習＋ファインチューニングの場合が一貫して高い性能を示した





アブレーション：ファインチューニングの有無

- 方法：ファインチューニングの場合と線形プロービングの場合で比較
- 結果：睡眠段階分類では性能差が小さかったものの、総合的にファインチューニングの場合が優位



時間位置埋め込みの可視化

- Fixed-time-positional embedding は周期的なパターン
→ サンプル番号に対して固定であるため、異なるサンプリング周波数に対応できない
- Learnable-time-positional embedding は非周期的なパターン
→ 柔軟な EEG の表現学習が可能




事前学習用パラメータ

- オプティマイザ：AdamW
- オプティマイザのパラメータ： $\beta = (0.9, 0.999)$, Weight Decay = 1×10^{-4}
- 初期学習率： 1×10^{-3}
- 学習率スケジューラ：ウォームアップエポックを 30 としたハーフサイクルコサイン (half-cycle cosine)
- バッチサイズ：256
- エポック数：100

マスク方法別の再構成結果とロス推移の比較

提案手法の方が周波数領域においても時間領域においても再構成結果が良い



アブレーション：マスク確率

発作型分類	Mask Ratio	Balanced Accuracy	Weighted F1 Score	Cohen's Kappa
	25%	0.9816±0.0053	0.9804±0.0066	0.9731±0.009
	50%	0.9789±0.0081	0.9791±0.0066	0.9712±0.0092
	75%	0.9835±0.0065	0.9817±0.0081	0.9748±0.0111
睡眠段階分類	Mask Ratio	Balanced Accuracy	Weighted F1 Score	Cohen's Kappa
	25%	0.9822±0.0123	0.9546±0.0166	0.9787±0.0081
	50%	0.9821±0.0118	0.9657±0.0135	0.9842±0.0058
	75%	0.9643±0.0142	0.9474±0.0114	0.9756±0.0042
てんかん様活動検出	Mask Ratio	Sens	Prec	FPr
	25%	0.7625±0.0043	0.4161±0.0243	0.0236±0.0006
	50%	0.7542±0.0178	0.4039±0.0187	0.0247±0.0018
	75%	0.735±0.0305	0.4105±0.0321	0.0271±0.0033
SWI 定量化	Mask Ratio	<i>SW I_{error}</i>	PCT-1	PCT-10
	25%	0.0322±0.0019	0.2164 ±0.0145	0.9698±0.0122
	50%	0.0336±0.0036	0.2327±0.0254	0.9647±0.0227
	75%	0.0351±0.0028	0.2087±0.0226	0.9575±0.0152